实验一：文本分类实验报告

课程：当代人工智能　任务：新闻文本 10 分类　环境：Python 3.14 + scikit-learn 1.9　2026 年 10 月

GitHub 链接：[4a2b2/lab1]

一、实验目标与数据

本实验以新闻文本 10 分类为任务，目标为：掌握文本预处理与 TF-IDF 特征工程，实践朴素贝叶斯（NB）、支持向量机（SVM）、逻辑回归（LR）、多层感知机（MLP）四种经典分类算法，学会基于验证集进行模型比较、超参数调参与结果分析。

数据集已预划分：训练集 7368 条（含标签 target∈{0,…,9}，类别基本均衡，每类 705–747 条）、无标签测试集 2457 条；实验中对训练集再按 8:2 分层抽样，得训练子集 5894 条与验证集 1474 条用于调参。原始文本为新闻组邮件格式，含 From、Subject、Organization、Lines 等头字段及正文。

二、实验方法

（1）文本预处理：原始邮件含大量与主题无关的元信息。处理流程为——提取 Subject 行内容（主题词区分力强）拼接到正文前；以首个空行分隔，删除其余邮件头字段；删除以「>」开头的引用行；用正则去除邮箱地址；仅保留英文字母、合并空格并统一转小写。示例：清洗前「From: … Subject: NeXT cube board monitor cable? Organization:…」，清洗后「hi all quick question could someone please send me a pinout of the cable that goes between a next cube and the monitor…」，可见噪声头字段被剔除、主题信息得以保留。

（2）特征工程与消融：将文本转为 TF-IDF 向量。为确定配置，以 SVM(linear,C=10) 为基准展开消融对比，结果见下表。可见词表规模越大、并引入二元语法（bigram）后性能显著提升，因为 bigram 能捕获「computer science」这类短语级语义。最终采用 max_features=20000、ngram_range=(1,2)、stop_words=english；向量化器仅在训练子集上 fit，再 transform 验证/测试集，杜绝数据泄露。

TF-IDF 配置	词表规模	n-gram	验证集准确率	加权 F1
配置 A	5,000	(1,1)	0.8100	0.8105
配置 B	10,000	(1,1)	0.8270	0.8275
配置 C（采用）	20,000	(1,2)	0.8514	0.8517

表 1 TF-IDF 特征配置消融对比

（3）四种模型：NB 基于「特征条件独立」假设，用词频统计直接估计后验概率，是文本分类的经典基线；线性 SVM 在高维稀疏空间中寻找最大间隔超平面；LR 用 softmax/sigmoid 将线性输出映射为概率，并借 L2 正则控制复杂度；MLP 通过带 ReLU 激活的隐藏层学习非线性决策边界。

（4）实验设计：固定随机种子 42、分层抽样、一次只改一个变量；以验证集准确率为选择标准，选出最优超参数后在全量训练集上重训并预测测试集。为观察真实训练动态（sklearn 的 SVC/LR 不输出逐迭代损失），另手写 mini-batch 梯度下降（batch=128）训练 LR、线性 SVM 与 MLP 并逐批记录损失。

三、实验结果

1. 基线与超参数调优（验证集）

模型	最优超参数	验证集准确率	加权 F1
朴素贝叶斯	默认 α=1.0	0.8562	0.8562
SVM (linear)	C=1	0.8602	0.8611
逻辑回归	C=10	0.8670	0.8670
MLP	隐藏层 (200,)	0.8704	0.8707

表 2 四种模型最优结果（基线→调优）

调参分析：SVM 随正则化参数 C 增大呈「先升后降」典型曲线——C=0.1 时严重欠拟合（0.7069），C=1 达峰（0.8602），C≥10 后过拟合（C=10 为 0.8514、C=100 降至 0.8263）。LR 在 C=1→100 区间稳定在 0.8616–0.8670，C=10 与 C=100 并列最优，说明 L2 正则使其对 C 不敏感、鲁棒性好。MLP 的隐藏层结构影响显著：单隐层加宽有效（(50,)→0.8677、(200,)→0.8704 最优），而两层结构 (100,50) 反降至 0.8575，表明在本数据规模下两层网络参数过多、更易过拟合，单隐层加宽是更优的容量扩展方式。此外，基线阶段四模型准确率集中在 0.856–0.865、彼此差距不足 1 个百分点，说明在本特征下「换模型」带来的收益有限，特征工程（尤其 bigram）的影响更为关键。

2. 最优模型（MLP(200)）分类别性能

类别	0	1	2	3	4	5	6	7	8	9
精确率	0.800	0.771	0.756	0.861	0.932	0.936	0.941	0.853	0.912	0.970
召回率	0.822	0.865	0.803	0.878	0.920	0.980	0.852	0.743	0.912	0.929
F1	0.811	0.815	0.779	0.870	0.926	0.957	0.894	0.794	0.912	0.949

表 3 MLP(200,) 各新闻类别（0–9）在验证集上的精确率/召回率/F1（macro F1=0.8708）

由表 3 可见：类别 5、9、4 最易区分（F1 分别 0.957、0.949、0.926），主题独特、特征词鲜明；类别 2（0.779）与 7（0.794）最难，类别 7 的召回率仅 0.743，说明其样本常被误分到相近主题类别。综合来看，10 类 F1 落在 0.78–0.96 之间，类别间不均衡提示存在若干主题相近、词汇重叠的类别对。下图的混淆矩阵进一步印证：错误样本多集中在对角线附近的相邻类别（如 2↔1、7↔0、6↔2），属主题相近类别间的系统性混淆，而非随机误分。

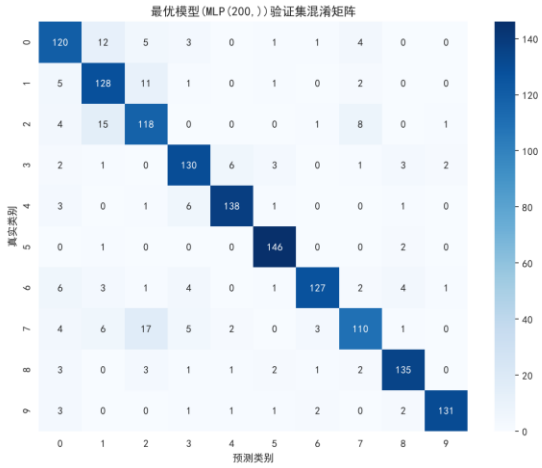


图 1 MLP(200,) 验证集混淆矩阵（对角线为正确分类）

3. 训练损失曲线

四种模型中，NB 是计数统计的闭式解、无迭代过程；sklearn 的 SVC/LR 分别由二次规划与 lbfgs 直接求解，均不输出逐迭代损失。故本实验手写 mini-batch 梯度下降（batch=128）训练三种模型并逐批记录损失，结果如图 2（手写模型验证集准确率 LR 84.26%、SVM 83.04%、MLP 84.33%，与 sklearn 实现相当，验证了实现的正确性）。

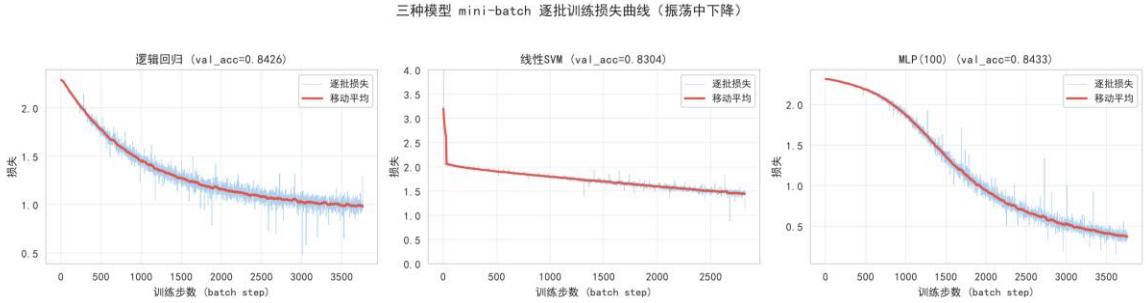


图 2 三种模型手写 mini-batch 逐批训练损失曲线（蓝：逐批损失；红：移动平均）

四、讨论与思考

（1）损失曲线为何「振荡中下降」：图 2 中蓝色逐批损失呈锯齿状上下抖动，红色移动平均则稳定下行。根源在于 mini-batch 采样的随机性——每批仅 128 条样本，各批的类别构成与难度不同，单批梯度方向带有噪声，故单步损失起伏；而噪声均值为零，移动平均后趋势单调下降，说明优化方向整体正确。这提示两点：其一，观察训练应看「趋势」而非单步数值，必要时用学习率衰减或增大 batch 来平滑；其二，sklearn 的 MLP.loss_curve_ 是 epoch 级平均损失，天然平滑，反而会掩盖这种批级波动——这也是我先前误以为曲线「不振荡」的原因。

（2）训练损失趋零 ≠ 泛化能力提升：MLP 的损失后期可降至接近 0，意味着模型已在训练集上「背答案」；此时若继续加深网络，训练损失更低但验证集不升反降（见表 (100,50)=0.8575）。这说明模型容量需与数据规模匹配，损失曲线需与验证集指标结合解读，单看训练损失会造成误判。

（3）线性模型为何不输 MLP：TF-IDF 将文本映射为 20000 维稀疏向量，线性可分性较高，且线性模型参数少、不易过拟合，故 SVM/LR 与 MLP 差距很小（0.8602–0.8704）。MLP 仅以约 1.3 个百分点微弱领先，说明在当前特征下非线性交互带来的增益有限——真正的瓶颈或许不在分类器，而在特征表示。

（4）超参数与模型容量的权衡：SVM 的 C 控制间隔与错分的折中，过大过小都差；MLP 的宽度比深度更管用，两层反而过拟合；LR 则对 C 不敏感。三者共同印证「没有免费午餐」：需针对模型特性与数据规模分别调参。

（5）局限与改进方向：本实验仅使用 TF-IDF 词频特征，无法捕获词序与上下文语义，类别 2/7 的混淆即源于此；改进可尝试——改用 Word2Vec/GloVe 或 BERT 等预训练表示、用字符级/词级混合 n-gram、以 K 折交叉验证替代单次划分以降低评估方差，并统计类别混淆对来针对性优化。整个过程我严格遵循「仅用训练集拟合向量化器、固定随机种子、一次只改一个变量」，深刻体会到可复现性对结论可信度的意义。

五、结论

本实验完成了文本分类全流程：预处理→TF-IDF→四模型对比→验证集调参→测试集预测（2457 条预测结果已保存至 predictions.csv）。关键结论：① bigram 特征显著提升性能（5000 词 unigram 0.8100 → 20000 词 unigram+bigram 0.8514）；② 最优模型为 MLP(200,)，验证集准确率 87.04%、加权 F1 0.8707；③ 线性模型（LR/SVM）以更少参数逼近 MLP，体现高维稀疏文本上线性模型的效率优势；④ 损失曲线呈「振荡中下降」，直观揭示了 mini-batch 训练的随机性本质与「训练损失下降≠泛化提升」的规律。综上，本实验不仅完成了规定任务，也通过损失曲线与分类别分析加深了对模型训练行为与误差来源的理解。

六、实验环境与可复现性说明

（1）环境与随机性控制：运行环境为 Python 3.14.8 / scikit-learn 1.9.1 / numpy 2.5.4 / pandas 3.0.6；全局固定 np.random.seed(42) 与各模型 random_state=42，划分采用 stratify=y 分层抽样，TF-IDF 仅在训练子集上 fit、验证/测试集仅 transform，从根本上避免数据泄露。

（2）脚本与输出：main.py 覆盖全流程，train_with_batch_loss.py 负责手写训练与逐批损失记录；输出 predictions.csv（2457 条预测，各类别 230–273 条，与训练集分布一致、无明显类别偏置）与 figures/ 下 6 张图表。所有调参结果均留存于日志与图表，按相同随机种子重跑可完全复现。